

3.方法论

3.1 方法总体思路

针对复杂自然场景下植物叶片病斑分割中存在的背景干扰强、病斑尺度变化大、边界模糊以及小病斑易漏检等问题，本文提出一种基于区域—边界—原型一致性协同学习的病斑分割方法。该方法以 ResNet50-U-Net 为基础框架，在保持编码—解码主干稳定性的前提下，从多尺度表征、几何边界约束与判别特征学习三个层面进行统一设计。具体而言，模型首先利用 ResNet50 编码器提取多层语义特征，并通过 U-Net 解码器逐步恢复空间分辨率；随后，在解码阶段引入尺度自适应多感受野增强模块，以提升模型对不同尺度、不规则形状病斑的表征能力；然后，构建区域分支与距离场边界分支，通过显式的区域—边界双向交互实现病斑主体与轮廓的协同优化；最后，在共享特征空间中引入病斑内部—病斑边界—背景三类原型一致性约束，增强特征可分性与跨场景泛化能力。通过区域损失、边界损失、原型对比损失和结构一致性损失的联合优化，模型能够同时提高分割完整性、边缘定位精度以及复杂背景下的鲁棒性。

3.2 网络总体结构

设输入图像为：

$$I \in R^{H \times W \times 3} \quad (1)$$

模型的目标是学习从输入图像到病斑分割结果的映射函数：

$$f_{\theta}(I) = \hat{Y} \quad (2)$$

本文网络由三部分组成：（1）编码—解码主干：完成病斑区域的基础语义分割；（2）尺度自适应多感受野增强模块：增强不同尺度病斑的响应能力；（3）区域—边界双向协同模块：联合优化病斑区域预测与边界几何定位；（4）三原型一致性学习模块：提升病斑内部、边界和背景在特征空间中的判别性。

整体过程可表示为：

$$\{F_1, F_2, F_3, F_4, F_5\} = \text{Encoder}(I) \quad (3)$$

$$D = \text{Decoder}(F_1, F_2, F_3, F_4, F_5) \quad (4)$$

$$D' = \Psi(D) \quad (5)$$

$$\hat{Y}_r, \hat{S}_b = \Phi(D') \quad (6)$$

其中, F_k 表示编码器第 k 层特征, D 为解码特征, $\Psi(\cdot)$ 表示尺度自适应多感受野增强与区域一边界交互映射, $\hat{Y}_r$ 为区域分支输出, $\hat{S}_b$ 为边界距离场分支输出。

3.3 编码—解码主干

本文以 ResNet50 作为编码器, 以 U-Net 作为解码器, 构建病斑分割的基础框架。

编码器从输入图像中逐步提取不同层级的特征, 可记为:

$$\{F_1, F_2, F_3, F_4, F_5\} = \text{Encoder}(I) \quad (7)$$

其中浅层特征 F_1, F_2 保留较多纹理和边缘信息, 深层特征 F_4, F_5 包含更丰富的语义信息。

解码阶段采用逐级上采样与跳跃连接相结合的方式恢复空间分辨率。

$$D_k = \phi(\text{Concat}(\text{Up}(D_{k+1}), F_k)) \quad (8)$$

这种结构可以有效融合深层语义信息和浅层细节信息, 为后续病斑主体定位和边界细化提供共享表示。

3.4 多尺度特征增强

已有研究已经反复证明, 真实病斑分割的困难之一就是病斑尺寸跨度大, 而且小病斑最容易漏检; 因此, 多尺度建模是必要的, 但单纯固定拼接多个空洞卷积分支还不够, 因为不同图像里真正有效的感受野并不一样。

为此, 本文不采用静态多尺度融合, 而是在解码特征 D_k 上构建尺度自适应多感受野增强模块。设输入解码特征为 D_k , 分别通过普通卷积和不同空洞率卷积得到:

$$Z_1 = \text{Conv}_{3 \times 3}(D_k) \quad (9)$$

$$Z_2 = \text{DilatedConv}_{3 \times 3}^{r=2}(D_k) \quad (10)$$

$$Z_3 = \text{DilatedConv}_{3 \times 3}^{r=3}(D_k) \quad (11)$$

然后利用全局平均池化获得图像级上下文向量, 并通过一个轻量门控函数生成三组非负权重:

$$[\alpha_1, \alpha_2, \alpha_3] = \text{Softmax}(g(\text{GAP}(D_k))) \quad (12)$$

其中 $\alpha_i \geq 0$ 且 $\sum_i \alpha_i = 1$ 。

最终融合特征定义为:

$$D'k = \text{Conv}_{1 \times 1}(\text{Concat}(\alpha_1 Z_1, \alpha_2 Z_2, \alpha_3 Z_3)) \quad (13)$$

这一设计的理论优势在于: 它不是把多个尺度简单相加, 而是让融合结果成为不同感受野分支的凸组合。这样做有两个好处。第一, 模型能够根据当前图像内容自适应突出小感受野或大感受野响应, 从而兼顾细小病斑和大范围病变。第二, 凸组合使得融合过程在数值上更稳定, 不容易因为某一分支异常放大而破坏训练, 理论上比硬拼接后直接卷积更稳。

3.5 区域一边界协同学习

3.5.1 区域分支

区域分支用于输出病斑主体区域概率图, 其形式为:

$$\hat{Y}_r = \sigma(\text{Conv}_{1 \times 1}(D')) \quad (11)$$

其中, $\sigma(\cdot)$ 为 Sigmoid 激活函数。

3.5.2 边界距离场分支

为增强边界监督的几何表达能力, 本文采用距离场回归方式构建边界分支。设病斑区域标签为 Y , 其边界集合为 ∂Y , 则任意像素 p 到边界的带符号距离定义为:

$$d(p, \partial Y) = \begin{cases} +\min_{q \in \partial Y} \|p - q\|_2, & p \in Y \\ -\min_{q \in \partial Y} \|p - q\|_2, & p \notin Y \end{cases} \quad (12)$$

将其归一化后得到边界距离场真值:

$$S_b = \text{Normalize}(d(p, \partial Y)) \quad (13)$$

边界分支输出表示为:

$$\widehat{S}_b = \text{Tanh}(\text{Conv}_{1 \times 1}(D_b)) \quad (14)$$

其中, D_b 表示由共享解码特征映射得到的边界特征, $\text{Tanh}(\cdot)$ 用于将输出约束在 $[-1,1]$ 区间。

相比于传统的二值边界监督, 距离场表示能够提供更加连续的几何约束信息, 从而增强模型对病斑边缘过渡区域的刻画能力。

3.5.3 区域—边界双向交互

为增强区域分支与边界分支之间的协同作用, 本文进一步在特征层引入双向交互机制。首先, 由区域特征和边界特征分别生成注意映射:

$$A_r = \sigma(\text{Conv}_{1 \times 1}(D'_r)) \quad (15)$$

$$A_b = \sigma(\text{Conv}_{1 \times 1}(D_b)) \quad (16)$$

然后, 利用边界注意映射对区域特征进行引导, 利用区域注意映射对边界特征进行约束, 得到交互后的特征表示:

$$\widetilde{D}_r = D'_r \odot (1 + A_b) \quad (17)$$

$$\widetilde{D}_b = D_b \odot (1 + A_r) \quad (18)$$

其中, $\odot$ 表示逐元素乘法。

该机制能够利用边界信息强化区域特征在轮廓附近的表达能力, 同时利用区域信息抑制边界分支在复杂背景纹理上的伪响应, 从而实现区域预测与边界定位的协同优化。

3.6 原型一致性学习

复杂自然场景下, 叶脉、阴影、反光和背景纹理等干扰因素容易与病斑边缘产生特征混叠, 导致模型在复杂背景中的泛化能力下降。为增强共享特征空间的判别性, 本文引入原型一致性学习机制, 在特征空间中显式构建病斑内部、病斑边界和背景三类原型。

设最终共享特征图为:

$$F \in R^{C \times H \times W} \quad (19)$$

根据真实标签将像素划分为病斑内部集合 Ω_{in} 、病斑边界集合 Ω_{bd} 和背景

集合 Ω_{bg} ，对应三类原型分别定义为：

$$P_{in} = \frac{1}{|\Omega_{in}|} \sum_{p \in \Omega_{in}} F(p) \quad (20)$$

$$P_{in} = \frac{1}{|\Omega_{in}|} \sum_{p \in \Omega_{in}} F(p) \quad (21)$$

$$P_{in} = \frac{1}{|\Omega_{in}|} \sum_{p \in \Omega_{in}} F(p) \quad (22)$$

对于任意像素特征 $F(p)$ ，定义基于原型的对比约束为：

$$L_{proto} = -\log \frac{\exp(\text{sim}(F(p), P_{yp}) / \tau)}{\sum_{c \in \{in, bd, bg\}} \exp(\text{sim}(F(p), P_c) / \tau)} \quad (23)$$

其中， $\text{sim}(\cdot, \cdot)$ 表示余弦相似度， τ 表示温度系数， P_{yp} 表示像素 p 所属类别对应的原型。

通过该机制，模型能够显式压缩类内特征差异、增大类间特征间隔，从而提高病斑内部、边界和背景之间的可分性，增强复杂自然场景下的鲁棒分割能力。

3.7 联合损失函数

为实现区域分割、边界定位和特征判别的统一优化，本文设计联合损失函数，由区域损失、边界损失、结构一致性损失和原型一致性损失四部分组成。

3.7.1 区域损失

区域分支采用二值交叉熵损失、Dice 损失和 Focal Tversky 损失的加权组合，以缓解类别不平衡并增强对小病斑样本的关注：

$$L_{region} = \lambda_{r1} L_{BCE} + \lambda_{r2} L_{Dice} + \lambda_{r3} L_{FT} \quad (24)$$

3.7.2 边界损失

边界分支采用距离场回归损失和边界带 Dice 损失联合监督，其定义为：

$$L_{boundary} = \lambda_{b1} L_{smoothL1}(\widehat{S}_b, S_b) + \lambda_{b2} L_{Dice}^{band} \quad (25)$$

其中， $L_{smoothL1}$ 用于约束预测距离场与真实距离场之间的数值差异， L_{Dice}^{band} 仅在边界邻域范围内计算，以强化轮廓区域的拟合能力。

3.7.3 结构一致性约束

为保持区域预测与边界预测在空间结构上的一致性，定义区域预测的边缘响应为：

$$\nabla(\hat{Y}_r) = \text{Sobel}(\hat{Y}_r) \quad (26)$$

边界预测的梯度响应为：

$$\nabla(\hat{S}_b) = \text{Sobel}(\hat{S}_b) \quad (27)$$

则结构一致性损失定义为：

$$L_{cons} = \frac{1}{HW} \sum_{i,j} \left| \nabla \hat{Y}_r(i,j) - \nabla \hat{S}_b(i,j) \right| \quad (28)$$

该损失有助于增强病斑主体预测与边缘轮廓预测之间的几何一致性，提高最终分割结果的边界清晰度。

3.7.4 总损失

最终总损失定义为：

$$L_{total} = L_{region} + \lambda_1 L_{boundary} + \lambda_2 L_{cons} + \lambda_3 L_{prato} \quad (29)$$

其中， λ_1 、 λ_2 和 λ_3 为平衡系数。

该损失函数从区域、边界和结构一致性三个层面约束模型训练，使网络既能够准确分割病斑主体区域，又能够提升边界定位质量。

3.8 训练与推理

训练阶段，给定数据集

$$D = \{(I_n, Y_n, S_{b,n})\}_{n=1}^N \quad (30)$$

其中， I_n 表示输入图像， Y_n 表示病斑区域标签， $S_{b,n}$ 表示由区域标签自动生成的边界距离场真值。模型通过最小化总损失函数完成参数学习：

$$\theta^* = \arg \min_{\theta} \frac{1}{N} \sum_{n=1}^N L_{total}(I_n, Y_n, S_{b,n}) \quad (31)$$

推理阶段，仅需输入待测图像 I ，模型即可输出病斑区域预测图 $\hat{Y}$ 和边界

距离场图 $\hat{S}_b$ 。最终分割结果由区域分支输出经阈值化后获得：

$$\tilde{Y}(i, j) = \begin{cases} 1 & \hat{Y}_r(i, j) \geq \delta \\ 0 & \hat{Y}_r(i, j) < \delta \end{cases} \quad (23)$$

其中 τ 为分割阈值，通常取 0.5。